

Seedance 端到端压力测试

批次 20260813-184409 · New API + 上游 AIPDD · 真实任务与真实扣费

总任务

50

成功率

100%

实际费用

¥64.00

并发波完成

376.58s

浏览器操练场会串行等待单个视频完成，因此本次由 1 个浏览器探针任务和 49 个通过同一公网 `/v1/videos` 路径同时释放的任务组成。性能分位数基于 49 个同时请求。

核心结果

提交任务/受理 P50 / P95

8.30 / 10.67s

端到端 P50 / P95

259.12 / 367.76s

有效吞吐


7.81 / min

最大排队 / 生成中

33 / 29


Seedance 并发任务端到端耗时

49 个同时提交的 API 任务；输出规格为 480p / 4 秒



任务状态变化时间线

基于每 5 秒一次的并发任务轮询统计



生成速度分位数

发送请求 → 提交任务/接口受理 (约 7-12 秒) → 排队等待 (平均约 101 秒) → 视频生成 (平均约 142 秒) → 任务完成

如何理解这些时间：提交任务耗时只是客户端发出 `/v1/videos` 到 New API 返回任务 ID 的时间，表示任务已进入系统，**不代表视频已经生成**。排队等待是已提交但尚未获得生成 Worker 的时间；视频生成耗时是开始生成到 `SUCCESS` 的时间；端到端完成耗时则从最初请求一直算到视频完成，包含以上所有阶段。

指标	最小	P50	P95	P99	平均	最大
提交任务/接口受理	7.21s	8.30s	10.67s	12.04s	8.75s	12.13s
排队等待 (近似)	5.65s	116.82s	208.38s	222.63s	101.24s	228.30s
视频生成阶段 (近似)	100.15s	138.55s	170.19s	197.91s	142.47s	209.59s
端到端完成	141.77s	259.12s	367.76s	375.99s	252.46s	376.58s

注意：7.81 个/分钟 (约每 7.68 秒完成一条) 是整个并发批次的**输出吞吐**，不是单个视频只需 8 秒。单个任务从发出请求到完成，平均约 252 秒；其中实际视频生成平均约 142 秒。

最大并发预测

上游稳态服务槽位 (估算)

18-22

推荐生产峰值

45 路

预测可用上限


65 路

高风险边界

100+ 路

预测采用饱和吞吐排队模型，以实测 **7.81 个任务/分钟** 为基准，并用 6.5 个任务/分钟作为保守情景。推荐峰值 45 路接近本次已验证负载且留有波动余量；预测可用上限 65 路的定义是：即使落入保守情景，单批任务预计仍可在 10 分钟内清空。

批次完成时限	保守 6.5/分钟	实测基准 7.81/分钟	乐观 9.0/分钟
5 分钟	32 路	39 路	45 路
6 分钟	39 路	47 路	54 路
10 分钟	65 路	78 路	90 路

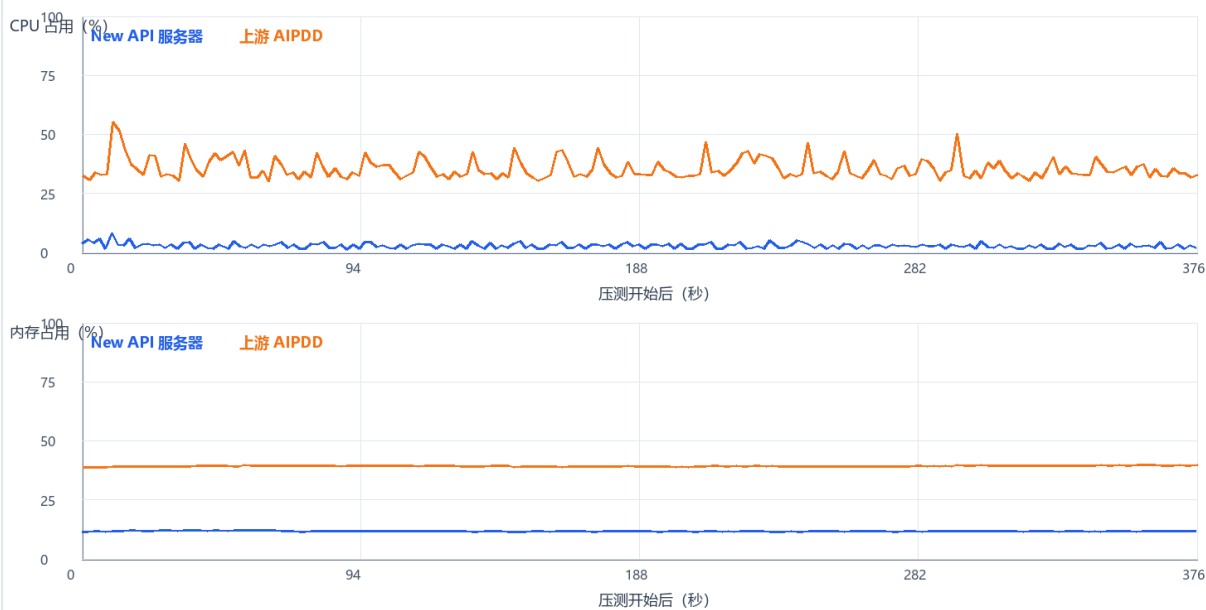


65 路是带有“10 分钟内清空”约束的预测可用上限，并非接口的绝对拒绝点。100 路预计需约 12.81 分钟清空，保守情景约 15.38 分钟，已进入明显排队风险区。该预测应通过下一轮 65 路真实任务验证。

服务器资源

主机	CPU 基线	CPU 平均	CPU 峰值	内存平均	内存峰值	Load 1m 峰值
New API 14.103.100.4	2.37%	2.84%	8.23%	11.71%	12.18%	0.15
上游 AIPDD 8.219.81.18	33.39%	35.44%	55.19%	39.32%	39.81%	1.65

压测活动期双服务器资源利用率



New API 网关没有形成资源瓶颈；主要延迟来自上游排队与视频生成。上游实际 GPU Worker 不在所提供服务器中，因此本报告不包含 GPU 和显存指标。

成本与账务


项目	测试前	测试后	变化
余额	¥1,359.35	¥1,295.35	-¥64.00

项目	测试前	测试后	变化
历史使用	¥109.85	¥173.85	+¥64.00
请求计数	35	85	+50

最低标价核对： $¥0.32 \times 4 \text{ 秒} \times 50 = ¥64.00$ ，与实际扣费完全一致。数据库保存了 50 条任务、状态全部为 `SUCCESS`。

关键证据截图

最低成本配置





任务执行中



浏览器探针成功

测试前余额



证据完整性

- 数据库任务：50 行，ID 193–242，全部 SUCCESS。
- 任务轮询：909 条事件。
- 服务器采样：New API 495 个，上游 AIPDD 495 个，采样错误为 0。
- 容量预测：capacity-forecast.json、capacity-forecast.csv 和中文预测图均保存在本目录。
- 报告归档：REPORT.html 与已转换的 REPORT.pdf 均保存在本目录。
- 原始文件、逐任务 CSV、汇总 JSON、脚本、截图和图表均保存在本目录。

完整方法、限制和后续容量建议见 REPORT.md 。

生成时间：2026-08-13 · Asia/Shanghai